

ML/AI-инженер с 3 годами коммерческого опыта в прикладном NLP и разработке генеративных систем. Проектирую и вывожу в эксплуатацию RAG-архитектуры, отказоустойчивых LLM-агентов, контуры автоматической оценки качества и сервисы локального инференса на FastAPI. Отвечаю за полный жизненный цикл решений от подготовки данных и контрастивного дообучения до построения поиска, мониторинга метрик, оптимизации задержек и внедрения сценариев с участием человека.

КЛЮЧЕВЫЕ НАВЫКИ

LLM & Agents

LangChain, LangGraph, Pydantic AI, MCP (Model Context Protocol), ReAct, Reflection, Tool Calling, Structured Outputs (Pydantic, Outlines), Human-in-the-loop, LoRA/QLoRA/PEFT, Guardrails.

RAG & Search

Qdrant, FAISS, Hybrid Search (Dense + BM25), Cross-Encoder Reranking, Query Rewriting, Semantic Chunking, Domain Fine-Tuning (multilingual-e5), NER (BIO scheme), Text Classification.

ML & Backend

Python, FastAPI, AsyncIO, PostgreSQL, SQLAlchemy, REST API, Redis, PyTorch, Hugging Face Transformers, CatBoost, LightGBM, scikit-learn, C++ (pybind11, CMake), Git.

MLOps, Serving & Infra

Docker, MLflow, Airflow, vLLM (Prefix Caching), ONNX Runtime (Dynamic INT8), DeepEval, Active Learning, Data Drift (PSI, KL divergence); Знаком с: Kubernetes, Kafka, Prometheus, Grafana, OpenTelemetry, AWQ/GPTQ.

ОПЫТ РАБОТЫ

ML Engineer

IMBA IT, IT-консалтинг

Июнь 2023 — Июнь 2024
Москва

Разрабатывал NLP-контур для автоматизации первой линии технической поддержки федеральной розничной сети. Сервис принимал входящие обращения из Service Desk, писем и веб-форм, выполнял очистку текста, извлекал именованные сущности, находил дубликаты инцидентов и направлял тикеты в нужные очереди через FastAPI. Отвечал за подготовку выборок, обучение и калибровку моделей, офлайн-оценку, API-контракты и оптимизацию инференса.

КЛАССИФИКАЦИЯ И АКТИВНОЕ ОБУЧЕНИЕ

Иерархическая маршрутизация и извлечение сущностей

- Пересобрал обучающую выборку из 150–200 тысяч обращений, очистил текст от технических артефактов и цитат, выполнил маскирование персональных данных с сохранением кодов ошибок, номеров магазинов и названий оборудования.
- Настроил строгое разбиение данных по времени и перепискам для защиты от утечек, дообучил классификатор DeBERTa с focal loss и weighted sampling на 20 категорий и 300+ очередях, достигнув macro-F1 0.84–0.87 и автоматизировав 35–40% маршрутизации.
- Построил процесс активного обучения с отбором сложных примеров по максимальной энтропии и малой разнице уверенности между лидирующими классами.
- Обучил модель распознавания именованных сущностей по схеме BIO для выделения атрибутов тикета и настроил поиск похожих открытых инцидентов в индексе FAISS по косинусному сходству векторов.

ОПТИМИЗАЦИЯ ИНФЕРЕНСА

Калибровка уверенности и ускорение вычислений

- Откалибровал распределение вероятностей с помощью температурного масштабирования на отдельной валидационной выборке, устранил таким образом избыточную уверенность модели на редких и близких классах.
- Настроил индивидуальные пороги уверенности для каждой категории с учетом баланса precision и recall.
- Оформил этапы обработки запроса в API от валидации и токенизации до прямого прохода нейросети и постобработки через замер задержек p50, p95 и p99 при пиковых нагрузках.
- Экспортировал модель в ONNX и применил динамическое квантование INT8, быстрый токенизатор на Rust и LRU-кэширование, за счет этого снизил задержку инференса на CPU (p95) со 180–250 мс до ~75 мс.

Спроектировал и вывел в эксплуатацию AI-инфраструктуру для клиентской поддержки платформы: RAG-помощника, агентный граф на LangGraph, систему семантического поиска дубликатов инцидентов, контуры регулярной оценки качества и табличные модели предиктивной аналитики.

Агентный помощник оператора на LangGraph

- Спроектировал управляемый граф агента, объединяющий детерминированные правила, маршрутизацию запросов через LLM, вызов read-only инструментов, узел проверки ответов и контрольные точки для подтверждения действий оператором.
- Обеспечил строгую изоляцию клиентских данных за счет передачи идентификатора аккаунта на уровне сервера, ограничил число шагов в цикле агента; 85–88% черновиков принимались без правок, а ручная нагрузка на операторов снизилась на 20–25%.

RAG-система в закрытом контуре

- Реализовал конвейер RAG с семантическим разбиением текстов, гибридным поиском по sparse и dense векторам, переранжированием через cross-encoder и атомарным переключением алиасов коллекций в Qdrant без простоя сервиса.
- Развернул локальное исполнение модели Qwen2.5-7B на vLLM с автоматическим кэшированием префиксов системных инструкций, оптимизировал работу эмбедингов через ONNX Runtime и внедрил строгую проверку ссылок на первоисточники.

Оценка качества и регрессионное тестирование

- Собрал многоуровневый контур оценки качества, отдельно измеряющий recall@k и MRR, фактологическую точность генерации, корректность ссылок и отсутствие межклиентских утечек.
- Настроил версионирование промптов, конфигураций поиска и параметров моделей, внедрил автоматические регрессионные проверки в CI/CD для того, чтобы не допустить деградации качества перед релизом.
- Использовал подход LLM-as-a-judge для выявления расхождений и автоматического пополнения регрессионного набора тестов сложными случаями.

Аналитика, табличные модели и поиск инцидентов

- Дообучил модель multilingual-e5-base контрастивным методом на парах тикетов с hard negatives, добившись в связке с Qdrant точности Precision@5 0.91 и полноты Recall@5 0.82 при поиске массовых инцидентов.
- Разработал CatBoost-модель прогнозирования риска незавершения обучения по первым 7 дням активности (PR-AUC 0.46–0.49 против 0.28 у базовой модели).
- Внедрил регулярный пакетный анализ тональности и тематической структуры обратной связи с использованием RuBERT и HDBSCAN.

ЯЗЫКИ И СТЕК ТЕХНОЛОГИЙ

Языки: русский — родной; английский — B2 (техническая документация и профессиональная переписка).

Специализация: LLM-агенты, RAG-системы, локальный инференс, оценка качества моделей, дообучение эмбедингов, прикладной NLP и высоконагруженные сервисы.

Основной стек: Python, FastAPI, PostgreSQL, Docker, MLflow, Airflow, ONNX Runtime, vLLM, Qdrant, FAISS, C++ (pybind11).

Инструменты в инфраструктуре: Kubernetes, Kafka, асинхронные очереди (Redis Streams, Celery), Prometheus, Grafana, OpenTelemetry, методы квантования AWQ и GPTQ.